

Agentes e Sistemas Multiagente nas Smart Cities

Universidade do Minho Escola de Engenharia
Mestrado em Engenharia Informática

Abstract. As cidades têm registado uma profunda transformação impulsionada por tecnologias emergentes para melhorar a qualidade de vida urbana. Os Agentes e Sistemas Multiagente (MAS) assumem relevância pela sua capacidade de aumentar a eficiência, segurança, sustentabilidade e conforto urbano. O presente artigo analisa as aplicações destes sistemas no desenvolvimento de *smart cities*, evidenciando a sua contribuição para uma gestão urbana mais inteligente e adaptativa. Através de uma revisão sistemática da literatura, examinam-se três domínios: controlo de tráfego com veículos autónomos conectados, gestão inteligente de energia e sistemas de condução autónoma. Os resultados demonstram que os sistemas multiagente possibilitam uma gestão descentralizada dos recursos urbanos, promovendo eficiência energética e respostas a eventos imprevistos. Identificam-se desafios relacionados com escalabilidade computacional, interoperabilidade entre sistemas heterogêneos, segurança de dados e os custos de implementação. Conclui-se que os sistemas multiagente constituem uma abordagem promissora para o desenvolvimento de cidades sustentáveis, resilientes e centradas no bem-estar dos cidadãos.

Keywords: Agentes · Inteligência Artificial · Sistemas Multiagente · Smart Cities.

1 Introdução

Nos últimos anos, tem-se verificado uma profunda transformação nas cidades impulsionada pela adoção de novas tecnologias, com o objetivo de melhorar a qualidade de vida dos seus habitantes. Um dos campos que tem assumido particular relevância neste processo é o dos Agentes e Sistemas Multiagente (MAS), que se destacam pela sua capacidade de otimizar a eficiência, a segurança, a sustentabilidade e o conforto no contexto urbano.

Este artigo tem como objetivo analisar e apresentar diferentes soluções baseadas em Agentes e Sistemas Multiagente aplicadas ao desenvolvimento das *smart cities*, evidenciando de que forma estas tecnologias contribuem para uma gestão urbana mais inteligente e adaptativa. Pretende-se, assim, compreender como estas abordagens promovem uma melhoria efetiva na qualidade de vida dos cidadãos e na sustentabilidade das infraestruturas urbanas.

2 Definição e Caracterização

2.1 Agentes e Sistemas Multiagente

Tal como definido por Russell e Norvig, um agente é uma entidade capaz de perceber o ambiente através de sensores e de interagir com ele por meio de atuadores, constituindo um sistema autónomo orientado para a prossecução de objetivos específicos [14]. Wooldridge aprofunda esta definição ao descrever um agente como um sistema computacional inserido num determinado ambiente, que atua de forma independente para atingir os seus objetivos, determinando por si próprio as ações necessárias em vez de depender de instruções explícitas em cada situação [20]. Esta autonomia traduz-se na capacidade de operar sem intervenção direta de seres humanos ou de outros agentes, mantendo controlo sobre as suas ações e estado interno.

Os sistemas multiagente (MAS), por sua vez, são compostos por múltiplos agentes que colaboram entre si, cada um com existência própria, independência e um conjunto de capacidades que determinam o seu comportamento, objetivos e grau de autonomia. Estes sistemas assentam num modelo de controlo distribuído, onde agentes cooperativos e autónomos atuam de forma coordenada para cumprir tarefas específicas. Ao contrário dos sistemas centralizados, o poder de decisão é repartido por várias unidades autónomas que comunicam entre si segundo regras previamente estabelecidas.

2.2 *Smart Cities*

De acordo com Tekinerdogan et al., as *smart cities*, ou cidades inteligentes, utilizam tecnologias avançadas, para melhorar a qualidade de vida urbana, aumentar a eficiência dos serviços públicos e promover o desenvolvimento sustentável [17]. No cerne deste paradigma encontra-se a *Internet das Coisas* (IoT), uma rede de dispositivos físicos equipados com sensores, software e conectividade de rede que permite a recolha e partilha de dados em tempo real [21]. A conectividade inteligente assume-se como pilar fundamental ao integrar tecnologias digitais para formar uma rede que interliga diversos aspetos da vida cidadina, transformando a cidade num organismo que respira informação e permite respostas em tempo real aos desafios urbanos.

No contexto de sistemas multiagente, as *smart cities* assentam em vários princípios fundamentais que permitem uma gestão mais autónoma, eficiente e resiliente:

1. **Autonomia dos Agentes:** Os agentes inteligentes possuem autonomia para executar ações e tomar decisões com base em objetivos definidos, sem depender de intervenção humana constante. Esta característica permite que os sistemas urbanos reajam de forma eficaz e em tempo real a alterações no ambiente, aprimorando as operações automaticamente.
2. **Comunicação e Conectividade:** A comunicação eficiente — tanto entre agentes, como entre sensores e plataformas centrais — é essencial. Uma

infraestrutura robusta de redes digitais permite a troca em tempo real de grandes volumes de dados, favorecendo a colaboração entre diferentes setores e melhorando a coordenação das operações urbanas.

3. **Percepção e Monitorização Ambiental:** Sistemas de sensores inteligentes distribuídos pela cidade recolhem dados sobre diversos indicadores urbanos. Os agentes processam estas informações para identificar tendências, antecipar problemas e recomendar intervenções preventivas, tornando a gestão urbana mais proativa e menos reativa.
4. **Eficiência Energética e Sustentabilidade:** Os agentes das *smart cities* são programados para otimizar a utilização de recursos naturais, promovendo a eficiência energética e a sustentabilidade ambiental, financeira e social.
5. **Adaptação e Resiliência:** A capacidade adaptativa é fundamental para que as cidades respondam rapidamente a eventos imprevistos e ajustem automaticamente os seus parâmetros de funcionamento, garantindo maior resiliência urbana e segurança para os cidadãos.
6. **Participação Cidadã e Governação Colaborativa:** Os modelos mais avançados promovem a integração activa dos cidadãos no processo de tomada de decisão, recorrendo a plataformas digitais de participação, permitindo uma gestão mais democrática, inclusiva e transparente dos recursos e dos serviços urbanos.

3 Estratégia Metodológica

Este trabalho tem como objetivo elaborar uma investigação sobre potenciais casos e experiências existentes na literatura no âmbito da aplicação das tecnologias de Agentes e Sistemas Multiagente (MAS) nas cidades inteligentes, com especial foco nos transportes e na gestão urbana. Para cumprir esse objetivo, procedeu-se à recolha, análise e síntese de estudos relevantes relacionados com o tema, de modo a identificar tendências, desafios e oportunidades de aplicação.

Assim, a estratégia metodológica seguida para a elaboração deste trabalho compreendeu as seguintes etapas:

1. **Definição do tema:** A partir do conjunto de domínios fornecidos no enunciado do projeto, o grupo optou por investigar a aplicação de Agentes e Sistemas Multiagente no contexto das *smart cities*, com ênfase em áreas como o controlo de tráfego, veículos autónomos e gestão de energia.
2. **Seleção das bases de dados:** Recorreu-se maioritariamente a bases de dados científicas amplamente reconhecidas e fiáveis, tais como *IEEE Xplore*, *ScienceDirect*, *SpringerLink*, *Scopus*, *Google Scholar* e *Web of Science*, garantindo o acesso a publicações atualizadas e de qualidade comprovada.
3. **Definição das palavras-chave:** Para a pesquisa nas diferentes plataformas, foram utilizadas palavras-chave em inglês e português, incluindo: “agents”, “multi-agent systems”, “agent-based systems”, “artificial intelligence”, “intelligent transportation systems”, “smart grids” e “smart cities”. Estas expressões permitiram identificar publicações pertinentes ao tema e às suas diferentes áreas de aplicação.

4. **Critérios de seleção dos conteúdos:** O processo de seleção baseou-se em atributos como o título, o *abstract*, a introdução, os resultados obtidos, as conclusões e a língua de publicação (português ou inglês). Estes critérios asseguraram a compatibilidade e relevância dos trabalhos escolhidos em relação ao tema em estudo.

4 Potencias Aplicações de Sistemas Multiagentes nas *Smart Cities*

4.1 Controlo de Tráfego

Com a chegada dos *connected autonomous vehicles* (CAV), surgem oportunidades para tornar o controlo de tráfego de interseções mais eficaz e inteligente. Assim, uma nova proposta introduz uma “fase branca” nos semáforos das cidades, acrescentando uma nova luz branca ao farol [9]. Esta fase pretende permitir aos CAVs coordenarem-se entre si a travessia do cruzamento através da comunicação entre eles e com o próprio semáforo, funcionando como um sistema cooperativo. Na prática a luz branca acendera-se-ia apenas quando um número suficiente de CAVs se dirigisse à interseção, avisando os *connected human-driven vehicles* (CHV) que devem seguir o carro da frente – este que será um CAV – e confiar na coordenação dos veículos autónomos para gerir o fluxo de trânsito. Nos restantes momentos o semáforo funciona como habitual. Com a fase branca, passa a ser possível coordenar movimentos simultâneos de fluxos de tráfego conflitantes, desde que cada fluxo tenha pelo menos um CAV líder a guiar o grupo nessa direção. Os CAV comunicam entre si e com o semáforo, negociado o direito de passagem e coordenando as trajetórias de forma a evitar colisões. Assim, cada CAV funciona basicamente como um “controlador móvel” do trânsito durante a fase branca, liderando uma *platoon* (fila) que pode incluir CHVs logo atrás de si [9]. Os condutores humanos, por outro lado, não têm de se questionar sobre fórmulas matemáticas – a luz branca indica-lhes simplesmente que sigam o veículo que está em frente (ou que não o ultrapassem), reproduzindo o seu comportamento, ou seja, se o veículo da frente avançar, avançam, se este parar, também param.

Desta forma, durante a fase branca, os CAVs garantem a travessia segura e eficiente da interseção, enquanto os CHVs limitam-se a imitá-los e a manter a distância de segurança. Esta ideia configura um MAS, em que os CAVs atuam como agentes distribuídos que tomam decisões coordenadas de forma colaborativa.

Em vez de confiar todo o controlo a uma unidade central (como um controlador de trânsito convencional), a inteligência está distribuída pelos próprios automóveis: cada CAV decide localmente a sua ação de controlo com base nas informações partilhadas pelos outros veículos e pelas condições do semáforo, e negocia prioridades de passagem com os demais. Por exemplo, num modelo proposto por Niroumand et al. [10], cada CAV calcula uma trajetória ótima para si (respeitando critérios de segurança e tempo de viagem) e chega a um acordo com os outros através de comunicação Vehicle-to-Vehicle (V2V) iterativa, ajustando sucessivamente a sua trajetória para evitar conflitos.

Ao mesmo tempo os CAVs também participam numa votação distribuída para decidir a duração das fases do semáforo (incluindo a fase branca), escolhendo os parâmetros de temporização que obtiverem consenso entre os agentes. Assim, o semáforo passa a funcionar como um agente de apoio e sinalização para os CHV, enquanto os próprios veículos autônomos “orquestram” o fluxo através da interseção de forma descentralizada e adaptativa. Esta descentralização tira partido do poder computacional e sensorial dos CAVs e aumenta a robustez do sistema – se a configuração do trânsito mudar de repente (por exemplo chegada de mais veículos numa via), os agentes-veículo podem reagir de imediato, re-planeando as trajetórias e tempos de fase branca conforme necessário, em vez de terem de depender de um ciclo fixo de semáforo.

A ideia da fase branca foi originalmente introduzida por Niroumand em 2020 [9], utilizando simulações computacionais para demonstrar a sua viabilidade. Nesse primeiro estudo, o controlo do cruzamento baseava-se num agente central (o semáforo) que coordenava os CAVs e determinava quando ativar a fase branca. No entanto, este modelo centralizado enfrentava desafios de escalabilidade e a fase branca nem sempre era ativada com frequência ótima. Para melhorar a eficiência e contornar as limitações do controlo central, a abordagem foi evoluída para um modelo distribuído em trabalhos posteriores (2022-2023) [10]. Nesse novo modelo, foi apresentado um novo algoritmo de controlo ao nível do veículo, no qual os próprios CAVs coordenam entre si as passagens na interseção através de acordos iterativos e votações (cada CAV otimiza a sua trajetória individualmente e propõe também um plano de tempos de sinal). Importa referir que os benefícios tornam-se mais notórios à medida que aumenta a penetração de CAVs nas cidades, mas o estudo marca uma fase transitória entre veículos autônomos e convencionais, apresentando mesmo assim, uma redução entre 19,6% - 96,2% de redução total do delay nas interseções em relação a um semáforo convencional.

Por fim, um desafio crucial para a adoção da fase branca em cenários reais é a integração de peões. Os estudos iniciais focaram-se principalmente nos fluxos veiculares, assumindo que não haveria atravessamentos pedonais concorrentes. Recentemente Niroumand et al. propuseram uma extensão do conceito de fase branca que inclui explicitamente fases para peões no modelo de otimização [13]. Nesta abordagem, o semáforo continua a ter fases pedonais convencionais e a fase branca é intercalada apenas quando não há peões a atravessar e existem CAVs suficientes para a ativar. Assim, sempre que houver peões a solicitar passagem, o controlador atribuirá a fase verde e adiará a ativação de qualquer fase branca até que todos os peões tenham atravessado. Os resultados demonstraram ser possível conciliar a coordenação dos CAVs com a segurança dos peões, mas só é possível alcançar o tempo mínimo de delay no semáforo tanto para peões quanto para os condutores quando o *market penetration rate* (MPR) dos veículos autônomos chega a 100%.

Análise Crítica

A proposta da fase branca e os trabalhos de Niroumand et al. [9, 10, 13] apresentam vários pontos fortes. Primeiramente, a proposta exemplifica uma nova

forma de controlo de tráfego híbrida entre semáforos convencionais e a gestão totalmente autónoma de interseções. Em vez de eliminar completamente os semáforos (o que exigiria 100% de CAVs na via), esta abordagem introduz um quarto sinal que permite transicionar gradualmente para um paradigma orientado pelos agentes-veículo.

Nesse mesmo sentido, a robustez e a flexibilidade do sistema demonstra que ele é capaz de se adaptar a situações não ideais, como a falta de CAVs suficientes na frota ou a presença de peões. Nesses casos, o semáforo simplesmente reverte ao modo convencional.

No estudo de 2022, Niroumand et al. [10] transita para uma abordagem descentralizada ao distribuir o cálculo de rotas nos veículos. Dessa forma, evita-se sobrecarregar um controlador central à medida que o tráfego cresce. Cada veículo trata apenas da sua própria rota e negocia com os vizinhos, aumentando a escalabilidade e tornando o problema mais modular.

Apesar dos méritos do novo modelo, o estudo não foi testado no mundo real ainda, portanto, há limitações e desafios importantes a considerar. Um dos principais obstáculos é a dependência de infraestrutura de comunicação entre os veículos autónomos. Para que a fase branca funcione, é necessário que os veículos sejam capazes de comunicarem entre si, exigindo compatibilidade e fiabilidade.

Outro defasio que pode ser visto na prática é a hesitação ou desconfiança do condutor humano. O modelo ainda não considera falhas humanas dos condutores, nesse sentido, ao não compreender ou não confiar no sistema, um condutor poderia acabar não seguindo o veículo dianteiro ou travar inesperadamente. Esse comportamento pode perturbar a coordenação e até gerar riscos à segurança.

Em suma, a literatura sobre a fase branca em semáforos urbanos apresenta-se como uma ideia tecnicamente inovadora e promissora, que tem capacidade para revolucionar a gestão de tráfego em ambientes com veículos autónomos.

4.2 Distribuição e Gestão de Energia

A distribuição e gestão de energia nas *smart cities* representam um dos maiores desafios tecnológicos e estratégicos da atualidade. As redes elétricas tradicionais, com um modelo centralizado e hierárquico, estão a evoluir para sistemas inteligentes e distribuídos — conhecidos como *smart grids* — capazes de integrar fontes de energia renovável, armazenamento descentralizado e dispositivos de consumo inteligentes. Os sistemas multiagente (MAS) têm-se destacado como uma abordagem eficaz para enfrentar a complexidade inerente a estas redes, permitindo a coordenação e otimização de múltiplos componentes energéticos de forma autónoma e colaborativa.

Num contexto urbano, os MAS possibilitam que agentes inteligentes monitorem, decidam e atuem localmente em unidades energéticas, como edifícios, painéis solares, baterias e veículos elétricos conectados à rede, mantendo simultaneamente uma visão global de equilíbrio energético. Cada agente pode negociar e ajustar a sua produção ou consumo de energia com base nas condições de mercado, na previsão de consumo e na disponibilidade de recursos, contribuindo assim para uma operação mais estável, eficiente e sustentável da rede.

De acordo com Jabeur et al. [6], a aplicação de sistemas multiagente na gestão de micro-redes permite otimizar o uso de recursos energéticos, equilibrando a produção e o consumo em tempo real. No estudo apresentado, os autores desenvolveram um modelo híbrido que integra a plataforma JADE, para gestão dos agentes, e o MATLAB/Simulink, para simulação física da rede elétrica. O sistema proposto coordena diferentes agentes — representando painéis solares, baterias e cargas elétricas — de modo a minimizar perdas de energia e reduzir custos operacionais, demonstrando ganhos significativos de eficiência em comparação com modelos de controlo centralizado.

De forma semelhante, Zhou e Erol-Kantarci [22] introduzem uma abordagem descentralizada baseada em aprendizagem por reforço multiagente (MARL - *Multi-Agent Reinforcement Learning*) para a gestão de micro-redes. O sistema utiliza algoritmos de Q-learning distribuído, onde cada agente aprende autonomamente políticas ótimas de consumo e armazenamento, ajustando-se dinamicamente às variações da procura e às condições de geração renovável. Os resultados evidenciam uma redução significativa nos custos de energia e maior estabilidade da rede em cenários com flutuações de carga e incerteza de produção solar e eólica.

Izmirlioglu et al. [5] apresentam um levantamento detalhado das aplicações de MAS em *smart grids*, com ênfase nas plataformas e ferramentas de simulação utilizadas. Os autores analisam e comparam diversas plataformas de desenvolvimento de agentes (como JADE, ZEUS e Volttron), essenciais para modelar a negociação de energia e a gestão de recursos. O estudo destaca a importância destas ferramentas para testar a fiabilidade e a eficiência de sistemas de controlo descentralizados antes da sua implementação prática.

Mais recentemente, Shojaeighadikolaei et al. [16] propuseram um enquadramento baseado em *Deep Reinforcement Learning* (DRL) multiagente para a resposta à procura (*demand response*) e gestão de energia distribuída. Nesta abordagem, os agentes aprendem políticas de decisão que maximizam o benefício energético global, reduzindo simultaneamente a necessidade de utilização de geradores de reserva e melhorando a estabilidade da rede. Os resultados experimentais confirmam que o sistema multiagente é capaz de adaptar-se a variações súbitas de consumo e a falhas parciais de comunicação sem comprometer o equilíbrio energético.

Em termos estruturais, os sistemas multiagente aplicados à energia podem ser organizados em três camadas principais:

1. **Camada de Percepção:** sensores e dispositivos IoT recolhem dados em tempo real sobre consumo, produção e armazenamento de energia;
2. **Camada de Decisão e Coordenação:** agentes inteligentes processam os dados, tomam decisões locais e comunicam entre si para equilibrar a rede e responder a alterações de contexto;
3. **Camada de Execução e Integração:** atuadores e sistemas de controlo implementam as decisões, ajustando a distribuição e trocas energéticas com a rede principal.

A Figura 1 exemplifica a arquitetura descrita acima. Nela observa-se a interação entre fontes de energia renovável, sistemas de armazenamento e cargas domésticas, coordenados por um controlador multiagente que gere o fluxo de energia e os sinais de controlo de forma distribuída.




Figure 1. Microgrid control by MAS

Fig. 1. Arquitetura de micro-rede controlada por sistemas multiagente.

Análise Crítica

O estudo desenvolvido por Jabeur et al. [6] apresenta uma arquitetura híbrida baseada em sistemas multiagente para otimização de micro-redes energéticas, demonstrando ganhos significativos de eficiência e redução de perdas. No entanto, o trabalho é limitado a simulações controladas, não sendo testado em ambientes urbanos reais, o que levanta dúvidas quanto à sua escalabilidade e robustez em redes de maior dimensão.

Por sua vez, Zhou e Erol-Kantarci [22] introduzem uma abordagem descentralizada com aprendizagem por reforço multiagente, na qual cada agente aprende a adaptar a sua estratégia de consumo e armazenamento. Os resultados mostram uma redução de custos e melhor estabilidade da rede, mas o modelo requer elevado poder computacional e depende fortemente da precisão dos dados de previsão, o que pode comprometer o desempenho em contextos reais de variabilidade elevada.

O levantamento de Izmirlioglu et al. [5] oferece uma visão compreensiva das plataformas de simulação e implementação de MAS para *smart grids*, identificando as ferramentas mais comuns e as suas aplicações. Contudo, embora a

comparação de plataformas como JADE e ZEUS seja útil, o estudo foca-se mais nas características técnicas das ferramentas do que na avaliação do desempenho empírico em cenários de larga escala. Tal como outros estudos de revisão, reforça que a interoperabilidade entre estas diferentes plataformas e a segurança dos protocolos de comunicação continuam a ser barreiras significativas.

Mais recentemente, Shojaeighadikolaei et al. [16] exploraram a integração de técnicas de *Deep Reinforcement Learning* para coordenação entre agentes em resposta à procura de energia. Embora a proposta demonstre melhorias significativas na adaptação a flutuações de consumo, o elevado custo de treino e a complexidade do modelo dificultam a sua aplicação prática em larga escala.

Em síntese, os estudos analisados confirmam o potencial dos sistemas multiagente para transformar a gestão de energia nas *smart cities*, promovendo eficiência e sustentabilidade. Todavia, a sua adoção efetiva exige superar desafios técnicos e infraestruturais, nomeadamente na segurança, interoperabilidade e validação empírica em ambientes urbanos reais.

4.3 Veículos Autónomos

Os veículos autónomos representam uma das mais ambiciosas transições tecnológicas no domínio da mobilidade, ao permitir que sistemas que anteriormente exigiam a atenção constante do condutor humano passem a assumir tarefas de condução com crescente grau de automação. De acordo com a norma SAE J3016, publicada pela SAE International, a função de condução pode ser classificada em seis níveis de automação, que vão do Nível 0, correspondente à ausência de automação, até ao Nível 5, em que o veículo é totalmente autónomo [15]. Esta classificação baseia-se, por um lado, no grau de intervenção do condutor nas tarefas de condução e, por outro, nas capacidades técnicas e nos equipamentos incorporados no veículo.

Nível 0 - Sem Automação: Neste nível, o condutor é totalmente responsável por todas as tarefas de condução. O veículo pode possuir sistemas de alerta, como avisos de colisão ou pontos cegos, mas estes não intervêm diretamente na condução.

Nível 1 - Assistência ao Condutor: O veículo pode assumir o controlo de uma única função de condução, como a aceleração ou a direção, através de sistemas como o cruise control adaptativo ou o assistente de manutenção de faixa.

Nível 2 - Automação Parcial: O veículo é capaz de controlar simultaneamente a aceleração e a direção, mas o condutor deve monitorizar constantemente o ambiente e estar preparado para intervir quando solicitado pelo sistema.

Nível 3 - Automação Condicional: O sistema automatizado pode realizar todas as tarefas de condução em determinadas condições (por exemplo, em autoestradas), mas o condutor deve estar disponível para assumir o controlo quando solicitado.

Nível 4 - Automação Alta: O veículo pode realizar todas as tarefas de condução de forma autónoma em condições específicas, como áreas geográficas definidas, sem necessidade de intervenção do condutor.

Nível 5 - Automação Completa: O veículo é capaz de realizar todas as tarefas de condução em qualquer condição, sem necessidade de intervenção humana, incluindo a ausência de volante ou pedais.

Para o desenvolvimento dos sistemas de condução autônoma (ADS - Autonomous Driving Systems) envolve a integração de tecnologias avançadas, incluindo sensores de percepção, algoritmos de inteligência artificial, sistemas de planejamento de trajetória e controlo automático de atuadores.

O ADS é estruturado em seis fases principais, conforme ilustrado na Figura 2.

O processo inicia-se com a camada de hardware dos sensores, responsável por recolher dados do ambiente circundante. Esta camada integra dispositivos como câmaras, radares, LIDARs¹, sensores ultrassónicos² e unidades de medição inercial (IMU)³. Estes sensores recolhem continuamente dados do ambiente circundante, constituindo a base de toda a percepção do veículo.

A segunda fase é a percepção, onde são executadas tarefas de rastreio de objetos, deteção de obstáculos e identificação de faixas de rodagem, na qual os dados capturados pelos sensores são processados através de algoritmos de visão computacional e aprendizagem automática.

A terceira fase corresponde à localização e mapeamento, onde o veículo determina a sua posição exata no espaço. Utiliza-se aqui uma combinação de GPS, LIDAR, mapas de alta definição (HD Maps) e algoritmos de SLAM (Simultaneous Localization and Mapping)⁴. Esta etapa é fundamental para garantir que o veículo saiba, com elevada precisão, onde se encontra em relação às vias, obstáculos e outros agentes.

De seguida da fase de avaliação de risco, em que o sistema analisa o contexto e antecipa situações potencialmente perigosas. São avaliadas as intenções e trajetórias prováveis dos outros utilizadores da via, bem como as condições ambientais, de forma a identificar cenários de conflito e calcular o nível de risco associado a cada possível decisão.

A quinta fase está relacionada com o planejamento de trajetórias e a tomada de decisão. Com base nas informações anteriores, o sistema seleciona o comportamento mais adequado e gera uma trajetória suave e segura que respeite as regras de trânsito e o conforto dos ocupantes.

Finalmente, a sexta fase envolve a camada de controlo do hardware, em que são definidos os comandos de condução, como ângulos de direção, aceleração e travagem [7].

¹ LIDAR (Light Detection and Ranging) é sensor que utiliza pulsos de luz laser para medir distâncias a objetos e superfícies.

² Sensores ultrassónicos são sensores que emitem ondas sonoras de alta frequência e medem o tempo que o eco demora a regressar, permitindo calcular distâncias a objetos próximos.

³ IMU combinam acelerómetros, giroscópios e, por vezes, magnetómetros para medir a aceleração, rotação e orientação do veículo em tempo real.

⁴ Algoritmos SLAM permitem que se construa um mapa do ambiente ao mesmo tempo que descobre a sua própria posição dentro dele, sem depender de GPS.




Fig. 2. Visualização dos Algoritmos ML dos Veículos Autônomos

De acordo com TechNewsToday [12] as empresas com maior notoriedade neste domínio destacam-se a Tesla, pela sua popularidade e a Waymo, pelos seus avanços tecnológicos.

A Tesla utiliza um sistema de condução assistida avançada denominado Autopilot, classificado como Nível 2 de automação [18]. O Autopilot baseia-se principalmente em câmaras de visão frontal, lateral e traseira, complementadas por sensores ultrassônicos e radares, permitindo uma perceção ambiental adequada para condução assistida, mas limitada em condições complexas ou imprevistas.

Já a Waymo, subsidiária da Alphabet (Google), desenvolveu o sistema Waymo Driver, classificado como Nível 4 de automação [19]. Os seus veículos equipados com este sistema podem operar sem intervenção humana em ambientes específicos, como zonas urbanas mapeadas ou autoestradas designadas. Para alcançar este nível de autonomia, a Waymo integra um conjunto avançado de sensores: câmaras para visão em tempo real, LIDARs para mapeamento 3D e deteção de obstáculos, radares para monitorização de objetos em movimento e unidades de medição inercial (IMU) para avaliar a dinâmica do veículo. Esta redundância de sensores permite ao veículo interpretar o ambiente de forma muito mais precisa e tomar decisões de condução autónomas com maior segurança.

Análise Crítica

O estudo realizado pela KPMG em 2020, intitulado "Índice de Prontidão para Veículos autónomos", avalia o grau de preparação de 30 países para a adoção de veículos autónomos. O relatório destaca que, embora haja avanços significativos em tecnologia e inovação, ainda existem desafios consideráveis em áreas como infraestrutura rodoviária, aceitação do consumidor e regulamentação. Além disso, a pesquisa aponta que a prontidão para veículos autónomos varia significati-

vamente entre os países, com Singapura liderando o índice devido a políticas públicas favoráveis e investimentos em infraestrutura inteligente [3].

Por outro lado, um estudo conduzido pela Universidade da Flórida Central, publicado em 2024, analisou dados de acidentes envolvendo veículos autônomos e conduzidos por humanos na Califórnia. Os resultados indicam que, em condições normais de condução, os veículos autônomos apresentam taxas de acidentes inferiores às dos veículos conduzidos por humanos. No entanto, foram identificadas exceções em situações de pouca luz e em curvas, onde os veículos autônomos demonstraram desempenho inferior, sugerindo a necessidade de aprimoramento dos sistemas de percepção nessas condições específicas [11].

Além disso, uma dissertação da Universidade Nova de Lisboa, publicada em 2023, realiza uma análise crítica dos requisitos de projeto para estradas destinadas a veículos autônomos. O estudo enfatiza a importância de adaptar a infraestrutura rodoviária existente, considerando aspectos como sinalização inteligente, comunicação veículo-infraestrutura e a necessidade de atualização das normas de construção para acomodar as especificidades dos veículos autônomos. A pesquisa também destaca que a integração bem-sucedida dos veículos autônomos depende não apenas da tecnologia embarcada, mas também de uma infraestrutura rodoviária adequada e atualizada [2].

Em suma, embora os veículos autônomos apresentem avanços promissores em segurança e eficiência, sua implementação em larga escala enfrenta desafios multifacetados que envolvem tecnologia, infraestrutura e aceitação social.

5 Desafios

Os agentes e sistemas multiagente apresentam um elevado potencial para transformar a gestão das *smart cities*. No entanto, persistem desafios significativos que afetam a sua aplicabilidade e eficácia:

Escalabilidade e Exigência Computacional: A simulação e implementação de sistemas multiagente em larga escala exigem elevados recursos computacionais. O aumento do número de agentes e da complexidade do ambiente provoca maior consumo de recursos e tempos de execução mais longos. Em contextos urbanos densos, com milhares de dispositivos IoT a interagir simultaneamente, a coordenação eficiente torna-se especialmente desafiante, podendo sobrecarregar as infraestruturas existentes [8].

Interoperabilidade e Padronização: A ausência de normas e protocolos comuns dificulta a integração entre sistemas de diferentes fornecedores. Sistemas provenientes de diversos fornecedores utilizam frequentemente protocolos de comunicação incompatíveis, dificultando a integração harmoniosa entre sensores, infraestruturas de iluminação inteligente, sistemas de gestão de resíduos e outros componentes da arquitetura urbana. Tecnologias como a *blockchain* têm sido exploradas para promover uma interoperabilidade segura entre serviços [1].

Segurança e Privacidade de Dados: Os sistemas multiagente processam grandes volumes de dados sensíveis, como padrões de mobilidade e consumo energético. Falhas num único agente podem propagar-se e comprometer o sistema

global, exigindo *frameworks* robustos de encriptação, autenticação e auditoria, em conformidade com as políticas de proteção de dados [4]. A interdependência das infraestruturas urbanas intensifica os desafios técnicos e sociais da segurança e gestão da informação.

Complexidade dos Sistemas Urbanos: A diversidade de serviços urbanos e modos de transporte torna difícil modelar as interações do ecossistema urbano. É essencial compreender o impacto destes sistemas complexos e garantir que os agentes se adaptam à incerteza e dinamismo dos ambientes urbanos.

Validação Empírica e Aplicabilidade Prática: Grande parte da investigação baseia-se em simulações, com escassez de implementações em ambientes urbanos reais. A transição de protótipos laboratoriais para cenários reais enfrenta desafios ligados à imprevisibilidade do ambiente urbano e ao comportamento humano não modelado [8].

Custos de Implementação e Manutenção: A implementação de sistemas multiagente é financeiramente exigente, sobretudo para cidades com orçamentos limitados. Os custos envolvidos incluem não apenas o desenvolvimento e a instalação dos diversos agentes e sensores, mas também a manutenção contínua, atualizações de software e hardware e a capacitação de equipas técnicas especializadas.

6 Conclusões

Ao longo deste artigo, verificou-se que os sistemas multiagente constituem uma abordagem promissora para o desenvolvimento de cidades mais inteligentes, sustentáveis e responsivas. A integração destas tecnologias permite uma gestão descentralizada e adaptativa dos recursos urbanos, potenciando uma utilização mais eficiente da energia, uma mobilidade otimizada e uma maior qualidade de vida para os cidadãos.

Embora tenham sido apresentadas diferentes soluções, algumas ainda estão em fases de desenvolvimento, em que foram realizados poucos testes, ou seja podem nem vir a ser implementadas, ou podem surgir novas soluções que sejam mais adequadas, eficientes, confiáveis e mais escaláveis.

Observa-se ainda que a implementação de qualquer uma destas soluções apresentadas vai exigir um grande período de testes e adaptação da cidade e dos seus habitantes para se habituarem a um quotidiano diferente do atual. De certa forma, as diferentes abordagens apresentadas demonstram que, no futuro, serão implementadas soluções inovadoras, adaptadas às necessidades das futuras cidades inteligentes.

References

1. Biswas, S., Yao, Z., Yan, L., Alqhatani, A., Bairagi, A.K., Asiri, F., Masud, M.: Interoperability Benefits and Challenges in Smart City Services: Blockchain as a Solution. *Electronics* **12**(4), 1036 (February 2023). <https://doi.org/10.3390/electronics12041036>

2. de Castro Coelho Appleton Figueira, D.M.: Estradas para veículos autônomos: análise crítica aos requisitos de projecto (023), https://run.unl.pt/bitstream/10362/176314/1/Figueira_2023.pdf, acesso em 3 out 2025
3. International, K.: 2020 autonomous vehicles readiness index: Assessing the preparedness of 30 countries and jurisdictions in the race for autonomous vehicles. Tech. rep., KPMG International (2020), <https://assets.kpmg.com/content/dam/kpmg/br/pdf/2020/09/autonomous-vehicles-readiness-index-2020.pdf>, acesso em: 23out.2025
4. Ismagilova, E., Hughes, L., Rana, N.P., Dwivedi, Y.K.: Security, Privacy and Risks Within Smart Cities: Literature Review and Development of a Smart City Interaction Framework. *Information Systems Frontiers* **24**(2), 393–414 (2022). <https://doi.org/10.1007/s10796-020-10044-1>
5. Izmirliglu, Y., Pham, L., Son, T.C., Pontelli, E.: A survey of multi-agent systems for smartgrids. *Energies* **17**(15), 3620 (2024). <https://doi.org/10.3390/en17153620>, <https://www.mdpi.com/1996-1073/17/15/3620>
6. Jabeur, H., Derbel, N., Yassine, M.M.: A multi-agent system for optimal management of microgrid energy resources using jade and matlab/simulink. *International Journal of Electrical and Computer Engineering (IJECE)* **12**(2), 1153–1160 (2022). <https://doi.org/10.11591/ijece.v12i2.pp1153-1160>, <https://ijece.iaescore.com/index.php/IJECE/article/view/25752>, acesso em: 25 out. 2025
7. Liu, Q., Li, X., Yuan, S., Li, Z.: Decision-making technology for autonomous vehicles: Learning-based methods, applications and future outlook. *arXiv preprint arXiv:2107.01110* (2021), <https://arxiv.org/pdf/2107.01110>
8. Nezamoddini, N., Gholami, A.: A Survey of Adaptive Multi-Agent Networks and Their Applications in Smart Cities. *Smart Cities* **5**(1), 318–347 (March 2022). <https://doi.org/10.3390/smartcities5010019>
9. Niroumand, R., Hajibabai, L., Hajbabaie, A.: Joint optimization of vehicle-group trajectory and signal timing: Introducing the white phase for mixed-autonomy traffic stream. *Transportation Research Part C Emerging Technologies* (05 2020). <https://doi.org/10.1016/j.trc.2020.102659>
10. Niroumand, R., Hajibabai, L., Hajbabaie, A.: White phase intersection control through distributed coordination: A mobile controller paradigm in a mixed traffic stream (12 2022). <https://doi.org/10.48550/arXiv.2212.06191>
11. PPLware: Carros autônomos são mais seguros do que os conduzidos por humanos, mas há duas exceções. <https://pplware.sapo.pt/motores/carros-autonomos-sao-mais-seguros-do-que-os-condutores-humanos-mas-ha-duas-excecoes/> (2024), acesso em: 23out.2025
12. pramukhtech: Top companies leading the autonomous vehicle race in 2025. *Techy News Today* (2025), <https://techynewstoday.com/autonomous-vehicle/>, accessed: 23 Oct. 2025
13. Ramin Niroumand, Leila Hajibabai, A.H.: Advancing the white phase mobile traffic control paradigm to consider pedestrians p. 17 (3 2024). <https://doi.org/10.1111/mice.13178>
14. Russell, S.J., Norvig, P.: *Artificial Intelligence: A Modern Approach*. Prentice Hall, 3 edn. (2010)
15. SAE International: Sae levels of driving automation™ refined for clarity and refinements (2021), <https://www.sae.org/news/blog/sae-levels-driving-automation-clarity-refinements>, accessed: 2025-10-23

16. Shojaeighadikolaie, A., Keshavarz, S.S., Ardestani-Jaafari, M.S.: Multi-agent deep reinforcement learning framework for demand response and distributed energy management. arXiv preprint arXiv:2211.15858 (2022), <https://arxiv.org/abs/2211.15858>, acesso em: 25 out. 2025
17. Tekinerdogan, B., Ömer Köksal, Çelik, T.: System Architecture Design of IoT-Based Smart Cities. *Applied Sciences* **13**(4), 2578 (2023). <https://doi.org/10.3390/app13074173>
18. Tesla Team: The bigger picture on autopilot safety (2024), <https://www.tesla.com/blog/bigger-picture-autopilot-safety>, acedido: 23 de Outubro de 2025
19. Waymo LLC: Waymo driver Acesso em: 23 out. 2025
20. Wooldridge, M.: *An Introduction to MultiAgent Systems*. Wiley, 2 edn. (2009)
21. Zanella, A., Bui, N., Castellani, A., Vangelista, L., Zorzi, M.: Internet of Things for Smart Cities. *IEEE Internet of Things Journal* **1**(1), 22–32 (2014). <https://doi.org/10.1109/JIOT.2014.2306328>
22. Zhou, Y., Erol-Kantarci, M.: Decentralized multi-agent reinforcement learning for energy management in smart microgrids. *IEEE Access* **9**, 105757–105767 (2021). <https://doi.org/10.1109/ACCESS.2021.3100249>, <https://arxiv.org/abs/2103.04154>, acesso em: 25 out. 2025